

Título

Análisis de Datos de Generación Energética en Sistemas Fotovoltaicos utilizando Google Colab, Pandas y SQLite

Chabla Ariel

1. Introducción

La energía solar fotovoltaica constituye una de las principales fuentes de energía renovable utilizadas en la actualidad debido a su sostenibilidad y bajo impacto ambiental. El monitoreo constante de los sistemas fotovoltaicos permite evaluar su desempeño, identificar patrones de generación y detectar posibles anomalías que puedan afectar la producción energética.

El presente proyecto tuvo como objetivo aplicar técnicas de análisis de datos utilizando herramientas de software libre para procesar información proveniente de un sistema fotovoltaico. Para ello se empleó Google Colab como entorno de desarrollo, Pandas para el procesamiento de datos, SQLite para el almacenamiento de información estructurada y las librerías Matplotlib, y PyWalker para la generación de visualizaciones.

Asimismo, se trabajó con dos fuentes de información diferentes: un dataset en formato CSV y una base de datos SQLite, integrando ambos conjuntos de datos mediante operaciones de unión utilizando Pandas.

2. Marco Teórico

Google Colab

Google Colab es una plataforma basada en la nube que permite ejecutar notebooks de Python sin necesidad de instalar software localmente. Facilita el desarrollo colaborativo y el acceso a recursos computacionales desde cualquier navegador web.

Pandas

Pandas es una biblioteca especializada en la manipulación y análisis de datos estructurados. Permite realizar procesos de lectura, transformación, limpieza e integración de información proveniente de múltiples fuentes.

SQLite

SQLite es un sistema gestor de bases de datos relacional ligero y embebido. Se caracteriza por almacenar toda la información en un único archivo, facilitando la gestión y consulta de datos mediante SQL.

Matplotlib

San Cayetano Alto s/n
Loja-Ecuador
Telf.: (593-7) 370 1444
informacion@utpl.edu.ec
Apartado Postal: 11-01-608
www.utpl.edu.ec

Matplotlib es una biblioteca utilizada para la generación de gráficos estadísticos y científicos. Permite representar visualmente el comportamiento de variables numéricas mediante diferentes tipos de visualización.

PyWalker

PyWalker es una herramienta de análisis visual interactivo que facilita la exploración de datos mediante una interfaz gráfica similar a plataformas de inteligencia de negocios.

3. Descripción del Dataset usado

El proyecto utilizó un dataset que se encuentra en la herramienta Kaggle, relacionado con la generación energética de un sistema fotovoltaico. La información principal se almacenó inicialmente en un archivo CSV que contiene registros históricos de producción energética.

Las variables utilizadas fueron:

- DATE_TIME: Fecha y hora del registro.
- PLANT_ID: Identificador de la planta solar.
- SOURCE_KEY: Identificador único del inversor.
- DC_POWER: Potencia generada en corriente continua.
- AC_POWER: Potencia generada en corriente alterna.
- DAILY_YIELD: Producción energética diaria.
- TOTAL_YIELD: Producción energética acumulada.

Como complemento, se creó una base de datos SQLite que permitió almacenar la información procesada y realizar consultas estructuradas mediante SQL.

Durante la fase de transformación se generaron nuevas variables derivadas:

- EFFICIENCY: Eficiencia energética calculada a partir de la relación entre AC_POWER y DC_POWER.
- hora: Hora extraída de la fecha del registro.
- dia: Día del mes.
- ratio_conversion: Relación entre potencia AC y potencia DC.
- nivel_generacion: Clasificación del nivel de generación energética.

4. Descripción de los pasos realizados en el proyecto

Paso 1: Carga de datos

Se cargó el dataset principal desde un archivo CSV utilizando la librería Pandas. Posteriormente se realizó una exploración inicial mediante las funciones `head()`, `info()` y `describe()` para conocer la estructura de los datos.

Paso 2: Transformación de datos

La columna `DATE_TIME` fue convertida al formato de fecha y hora de Pandas para facilitar el análisis temporal. A partir de esta variable se generaron las columnas hora y día.

Paso 3: Creación de métricas

Con el objetivo de enriquecer el análisis se crearon nuevas métricas derivadas.

creación de la eficiencia energética, creación del ratio de conversión.

```
#Crear métricas nuevas
df['EFFICIENCY'] = (df['AC_POWER'] / df['DC_POWER']) * 100
df['EFFICIENCY'] = df['EFFICIENCY'].fillna(0)

#Clasificación de potencia
def clasificar_potencia(power):

    if power < 1000:
        return 'Baja'

    elif power < 3000:
        return 'Media'

    else:
        return 'Alta'

df['NIVEL_GENERACION'] = df['AC_POWER'].apply(clasificar_potencia)
#EXTRAER LA HORA DE LA FECHA
def obtener_hora(fecha):
    return fecha.hour

#RATIO DE CONVERSIÓN ENERGÉTICA
def calcular_ratio(dc_power, ac_power):
    if dc_power == 0:
        return 0
    else:
        return ac_power / dc_power
```

Paso 4: Creación de la base de datos

Se creó una base de datos SQLite denominada `solar.db` para almacenar la información procesada.

```

conn = sqlite3.connect('/content/solar.db')

consulta = """
SELECT *
FROM energia_fotovoltaica
"""

df_sql = pd.read_sql_query(consulta, conn)

conn.close()

df_sql.head()


```

	DATE_TIME	PLANT_ID	SOURCE_KEY	DC_POWER	AC_POWER	DAILY_YIELD	TOTAL_YIELD	EFFICIENCY	hora	nivel_generacion	ratio_conversion	dia
0	2020-05-15 06:00:00	4135001	1BY6WecLGH8j5v7	37.142857	3.585714	0.0	6259559.0	9.653846	6	Baja	0.096538	15
1	2020-05-15 06:00:00	4135001	1IF53ai7Xc0U56Y	53.500000	5.162500	0.0	6183645.0	9.649533	6	Baja	0.096495	15
2	2020-05-15 06:00:00	4135001	3PZuoBAID5Wc2HD	58.000000	5.585714	0.0	6987759.0	9.630542	6	Baja	0.096305	15
3	2020-05-15 06:00:00	4135001	7JYdWrtLSPkdw4	58.428571	5.628571	0.0	7602960.0	9.633252	6	Baja	0.096333	15
4	2020-05-15 06:00:00	4135001	McdE0feGgRqW7Ca	54.375000	5.250000	0.0	7158964.0	9.655172	6	Baja	0.096552	15

4.1. Breve descripción de las visualizaciones generadas

Generación solar promedio por hora (Matplotlib)


Se desarrolló una gráfica de líneas utilizando la librería Matplotlib para representar el comportamiento promedio de la potencia AC generada durante las diferentes horas del día. Para ello, los registros fueron agrupados mediante la variable hora y posteriormente se calculó el promedio de la variable AC_POWER.



La visualización permitió observar el comportamiento temporal de la generación fotovoltaica, identificando las horas de mayor producción energética y las variaciones existentes a lo largo del día. Los resultados muestran un incremento progresivo de la generación durante la mañana, alcanzando sus niveles más altos alrededor del mediodía y disminuyendo durante la tarde.

Distribución del nivel de generación energética (Matplotlib)


Se implementó una gráfica de barras para analizar la distribución de los registros clasificados según el nivel de generación energética. Para ello se utilizó la variable nivel_generacion, creada a partir de la potencia AC generada por el sistema.



La gráfica permitió identificar la cantidad de registros pertenecientes a cada categoría de generación (baja, media y alta), proporcionando una visión general del comportamiento operativo del sistema fotovoltaico durante el período analizado.

Producción energética por inversor (PyWalker)

Mediante PyWalker se desarrolló una visualización interactiva utilizando la variable SOURCE_KEY, que identifica a cada inversor del sistema, y la variable DAILY_YIELD, correspondiente a la producción energética diaria.



Esta visualización permitió comparar el rendimiento energético de los diferentes inversores, identificando aquellos equipos con mayor y menor aporte a la producción total del sistema. La herramienta PyWalker facilitó la exploración interactiva de los datos mediante filtros, ordenamientos y análisis visual dinámico.

5. Problemas encontrados durante el desarrollo

Durante la implementación se presentaron algunos inconvenientes técnicos. Uno de ellos fue la existencia de columnas duplicadas (NIVEL_GENERACION y nivel_generacion), lo que generó errores al almacenar los datos en SQLite. La solución consistió en eliminar la columna duplicada y mantener una única estructura de nombres.

Otro problema surgió durante la creación de visualizaciones temporales, cuando la columna hora aún no había sido generada. Para solucionarlo fue necesario extraer la hora desde DATE_TIME utilizando funciones de Pandas.

También se presentaron dificultades iniciales en la implementación de gráficos interactivos con Bokeh debido a diferencias respecto a Matplotlib, las cuales fueron corregidas mediante la adecuación del formato de datos requerido por la librería.

6. Conclusiones

Los resultados obtenidos permitieron comprobar que el comportamiento de la generación fotovoltaica sigue el patrón esperado para sistemas solares, alcanzando sus mayores niveles de producción durante las horas centrales del día.

La creación de métricas como EFFICIENCY y ratio_conversion permitió analizar con mayor detalle el rendimiento energético del sistema y estudiar el comportamiento del proceso de conversión eléctrica.

La integración de información proveniente de un archivo CSV y una base de datos SQLite demostró la utilidad de Pandas para consolidar datos de diferentes fuentes en un único conjunto de información.

Las visualizaciones desarrolladas con Matplotlib y PyWalker facilitaron la identificación de patrones de generación energética y permitieron interpretar de forma más eficiente los resultados obtenidos.

Este proyecto evidencia cómo las herramientas de software libre pueden utilizarse para desarrollar procesos de análisis de datos aplicados al monitoreo de sistemas fotovoltaicos.

Referencias

Link GitHub : https://github.com/agchabla97/Trabajo_acad-mico_final_Herramientas.git

Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. Computing in Science & Engineering, 9(3), 90–95.

McKinney, W. (2022). Python for Data Analysis (3rd ed.). O'Reilly Media.

Pandas Development Team. (2025). Pandas Documentation. <https://pandas.pydata.org>

SQLite Consortium. (2025). SQLite Documentation. <https://www.sqlite.org>

Bokeh Development Team. (2025). Bokeh Documentation. <https://docs.bokeh.org>

Kanaries. (2025). PyWalker Documentation. <https://docs.kanaries.net/pygwalker>

Google Colaboratory. (2025). Colaboratory Documentation. <https://colab.google>